Válogatott labdarúgó mérkőzések predikálása

Készítette: Sándor Zsombor

Adathalmaz

- Cél: Nemzetközi labdarúgó-mérkőzések kimenetelének (Hazai győzelem, Döntetlen, Vendég győzelem) predikciója gépi tanulással.
- Forrás: https://www.kaggle.com/datasets/martj42/international-football-results-from-1872-to-2017
- 1872-től egészen napjainkig minden eredmény megtalálható (havonta frissülnek az adatok)
- Adattisztítás és szűrés (Hogy az AI a modern focit tanulja meg):
    - Csak a 2000. január 1. utáni mérkőzéseket tartottam meg
    - Kizártam a barátságos meccseket(csak selejtezők,VB-k és EB-k maradtak)

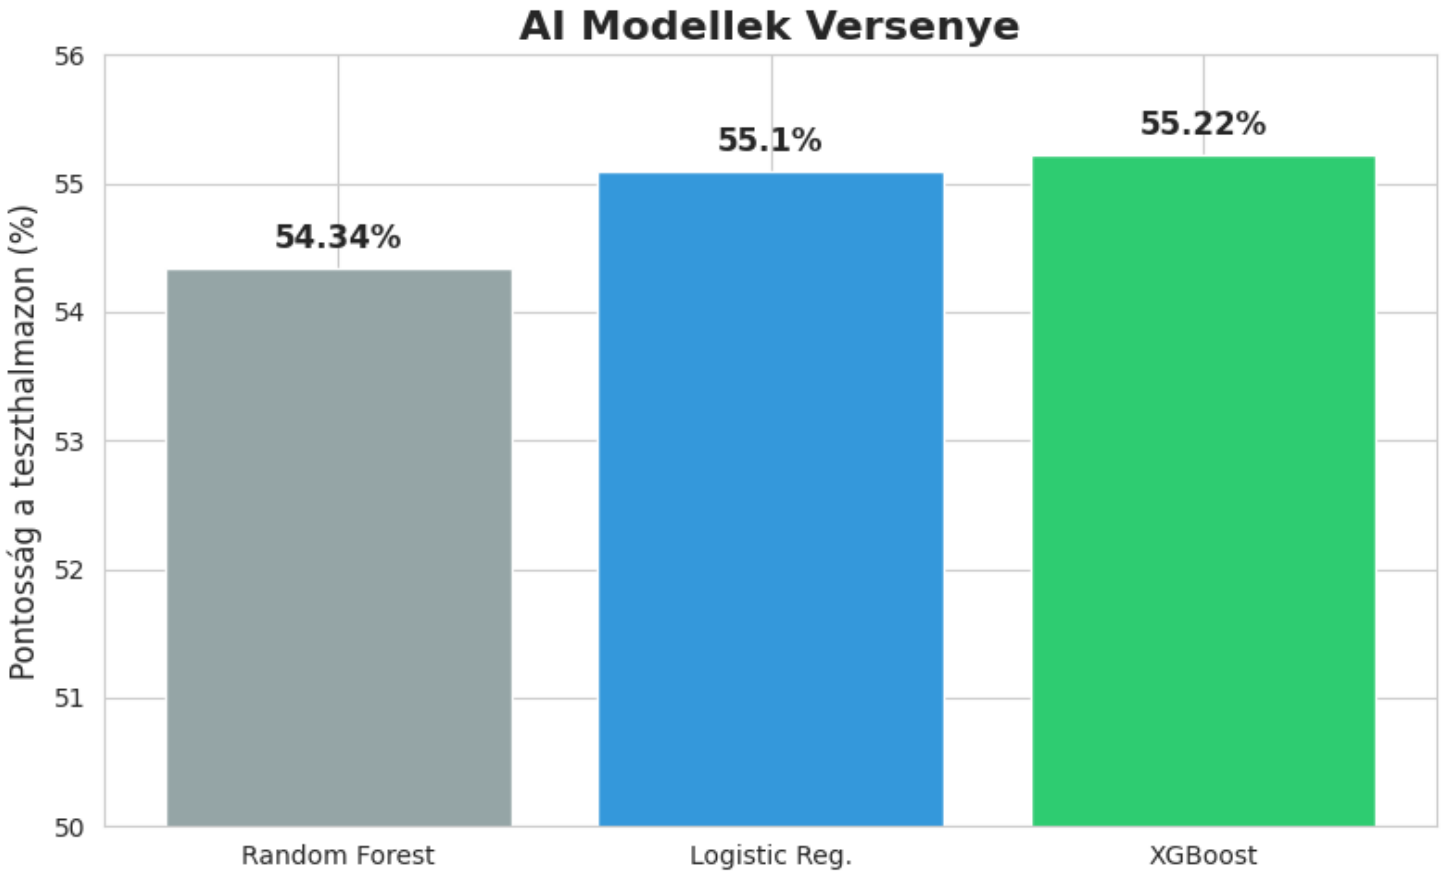
Adatfeldolgozás

- A kiindulási probléma: A nyers adathalmazban csak a végeredmény szerepelt, ami önmagában nem prediktív.
- Megoldás: Egyedi algoritmus írása, amely minden mérkőzésnél "visszanéz" az időben.
- Új attributumok:
  - Hazai lőtt gólok átlaga (utolsó 5 meccs)
  - Hazai kapott gólok átlaga (utolsó 5 meccs)
  - Vendég lőtt és kapott gólok átlaga (utolsó 5 meccs)
- Target kódolása: Többosztályos klasszifikációra (1 = Hazai, 0 = Döntetlen, 2 = Vendég).

Alkalmazott modellek

- V1 – Logistic Regression (Baseline modell):
    - Valószínűségi alapú statisztikai modell.
    - Alapvonalként (baseline) szolgált, hogy legyen mihez viszonyítani a komplexebb modellt.
- V2 – Random Forest Classifier (A Fő modell):
    - Döntési fák sokaságára épülő algoritmus, amely a fák független szavazatait átlagolja.
    - Kiválóan kezeli a sportadatokban lévő zajos és nem-lineáris összefüggéseket.
- V3 – XGBoost Classifier:
    - Szintén fákra épül, de szekvenciálisan: minden új fa az előző hibáit próbálja minimalizálni gradiens ereszkedéssel.

Modellek teljesítménye és értékelése



- A maximum elérése: Az eredmények közelsége (~55%) bizonyítja, hogy pusztán a formamutatókból (gólátlagokból) ez a predikciós plafon.

Deployment

- Technológiai architektúra: Python, Scikit-learn, Streamlit keretrendszer
- Modell-szerializáció: A betanított gépi tanulási "agy" és a csapatok legfrissebb forma-memóriája .pkl (pickle) formátumba kimentve.
- A Webalkalmazás működése:
    - Elválasztottam a betanítást a felhasználói felülettől (Production-ready állapot).
    - Interaktív, böngészőből elérhető UI (app.py), ahol a felhasználó két legördülő menüből választhat csapatot.
    - A modell ezredmásodpercek alatt ad valószínűségi százalékokat (predict_proba) a kimenetelekre.

Összegzés

- Mérföldkövek: Nyers adatok tisztítása, egyedi forma-kalkuláló algoritmus megírása, modell tanítása, interaktív webes publikálás Streamlit-tel.
- Tanulság: A válogatott mérkőzések előrejelzése extrém kihívás a ritka meccsek miatt, de a dinamikus formamutatók stabil alapot adnak a gépi tanulásnak.
- Továbbfejlesztési lehetőségek:
    - Más adatokat tartalmazó adatbázisokat felhasználva még megbízhatóbbá tenni a becslést

Köszönöm a figyelmet!